Entrega técnica del prototipo final

Modelo de predicción de devoluciones de inventario de equipos móviles

Grupo 5 · Maestría en Inteligencia Artificial Aplicada · Universidad de Las Américas
Guaján Perugachi Jimmy Israel · Martínez Ortega Jorge Washington · Vásquez Chávez Marco Vinicio · 26 de octubre de 2026

1. Dónde está todo

Repositorio: https://github.com/JimmyGuajan/capstone-devoluciones-udla (rama `main`).

- El repositorio es privado. El acceso de lectura se otorga a los evaluadores por invitación; también puede entregarse comprimido.
- El punto de partida es el `README.md` de la raíz: describe el problema, los requisitos, la ejecución paso a paso y el pipeline.
- Los datos del cliente no forman parte del repositorio (datos personales bajo la LOPDP). Una muestra sin identificadores permite ejecutar la demo y las pruebas.

2. Problema y solución

Una empresa de telefonía en Ecuador proyecta su demanda sin considerar cuántos equipos volverán de los distribuidores, lo que genera sobre-stock. El proyecto predice el volumen mensual de devoluciones por marca.

Definición del negocio: una unidad cuenta como devolución cuando cumple 60 días desde su despacho y sigue en poder del canal. Se cuenta una sola vez, el mes en que cruza el umbral. Se contrastó con listados reales del área de planificación: 99,75 % de coincidencia (799 de 801 equipos).

Solución: una regresión de Poisson con offset de exposición. Devoluciones esperadas = unidades en riesgo × tasa de la marca. La tasa se reestima cada mes con los 9 meses anteriores y se encoge hacia la tasa global (k = 300). Se compara con Random Forest y XGBoost, y con líneas base sencillas.

3. Requisitos y ejecución paso a paso

Requiere Python 3.12 (verificado con 3.12.4) y las versiones exactas de `requirements.txt`: pandas 2.2.3, numpy 2.0.2, scikit-learn 1.9.0, xgboost 2.1.3, shap 0.52.0, statsmodels 0.14.4, pyarrow 25.0.0, entre otras.

Con los datos del cliente, la cadena se reconstruye en este orden. Cada script compara su resultado con el artefacto existente en lugar de sobrescribirlo.

Paso	Comando	Produce
1	`python scripts/construir_v2.py`	Estadías y ciclo de vida por unidad
2	`Cuadernos 01 a 05`	Paneles y primeros modelos; decisión del modelo
3	`python scripts/construir_v6.py`	Extensión ago–sep 2026 y panel del modelo
4	`Cuaderno 06`	Prueba de 9 meses
5	`python scripts/walk_forward.py`	Validación walk-forward y líneas base
6	`Cuadernos 07 y 08`	Validación estadística; SHAP y equidad
7	`python scripts/entrenar_y_evaluar.py`	Evaluación final y modelo guardado
8	`python scripts/predecir.py --mes 2026-09`	Demo de predicción
9	`python -m pytest tests`	33 pruebas

Sin los datos del cliente: `python scripts/predecir.py --mes 2026-09 --panel docs/muestra/panel_modelo_muestra.csv` y `python -m pytest tests` funcionan con el panel de muestra. Se comprobó clonando el repositorio en una carpeta limpia.

4. Pipeline

Del inventario diario (14.007.314 filas) y los despachos (6.383.678) se obtienen los tramos donde estuvo cada equipo (775.024 estadías) y su permanencia en el canal (314.091 periodos). Contando las unidades que cumplen 60 días cada mes (39.798 eventos) se forma el panel marca × mes de 319 filas, 11 marcas y 29 meses. Sobre ese panel se entrena y se evalúa el modelo. La demo está en reports/html/demo_prediccion.html.

5. Organización del repositorio

Carpeta	Contenido
`src/`	Módulos: lectura de fuentes, definición del target, panel, modelo final, validación, seudonimización
`scripts/`	Pasos ejecutables de la cadena, entrenamiento, demo y generación de la página de demo
`notebooks/`	Ocho cuadernos, del análisis exploratorio a la interpretabilidad y equidad
`tests/`	33 pruebas del modelo, ausencia de fuga de información y seudonimización
`modelo/`	Modelo final entrenado (tasas por marca, ventana, k y dispersión)
`reports/`	Resultados: métricas en CSV, figuras, reportes HTML, evidencia de pruebas
`docs/`	Informes de entrega, solicitud de datos y datos de muestra sin identificadores
`data/`	Artefactos generados; local y no versionado

6. Resultados finales y métricas comparativas

Entrenamiento mayo 2024 a diciembre 2025; prueba sobre enero a septiembre de 2026. El criterio comprometido es un MAPE mensual de 15 % como máximo.

Modelo	MAPE	MAE	RMSE	WMAPE
Tasa de conversión (seleccionado)	4,1 %	41,0	69,9	0,116
Random Forest	5,2 %	49,0	63,6	0,118
XGBoost Poisson	9,5 %	76,4	89,7	0,179

Validación walk-forward de 21 orígenes, reentrenando en cada mes con solo el pasado:

Modelo	MAPE medio	IC 95 % (bootstrap)	Peor origen
Tasa de conversión	5,26 %	3,62 – 7,19	17,5 %
Random Forest	7,17 %	5,21 – 9,36	23,4 %
XGBoost Poisson	10,56 %	7,60 – 13,73	28,1 %
Naive (mes anterior)	34,96 %	22,28 – 54,01	196,1 %
Media móvil de 3 meses	41,18 %	–	320,8 %
Cero (no anticipa nada)	100,0 %	–	100,0 %

7. Evidencias de robustez y pruebas finales

- Walk-forward de 21 orígenes y bootstrap de 5.000 remuestreos. Solo 1 de los 21 orígenes supera el 15 % (junio de 2025, 17,5 %).

- Sobredispersión medida: $\phi = 8{,}9$. Con la corrección quasi-Poisson, los intervalos cubren el 95,2 % de los orígenes.
- 33 pruebas automáticas, con el resultado guardado en reports/pruebas_finales.txt. Una prueba de no-fuga cambia lo que ocurre en el último mes y comprueba que ninguna variable explicativa se mueve; se verificó que detecta tres fugas inyectadas a propósito.
- Reproducibilidad: los ocho artefactos de la cadena se reconstruyen idénticos desde los scripts; XGBoost es idéntico al bit entre ejecuciones y Random Forest coincide hasta 10^{-13}.
- Interpretabilidad (SHAP): la variable de unidades en riesgo explica el 70,6 % de la importancia en XGBoost y el 94,2 % en Random Forest.

8. Referencia a los anexos técnicos

Anexo del informe	Evidencia en el repositorio
1 · Diccionario de datos	src/fuentes.py, src/sources.py; docs/muestra/README.md
2 · Definición operativa de devolución	README.md (Definición del target); src/permanencia.py
3 · Acta de validación (99,75 %)	Cuaderno 03_antiguedad_inventario
4 · Flujo reproducible	README.md (El pipeline, Ejecución paso a paso); scripts/
5 · Explicabilidad (SHAP)	Cuaderno 08; reports/shap_dos_ensambles.csv
6 · Error por marca y modelo de equipo	Cuadernos 06 y 07; reports/cuadro_v6.csv; demo HTML
7 · Líneas base y alternativas	Cuadernos 05 y 07; reports/walkforward_con_lineas_base.csv

9. Limitaciones declaradas

- Grano: el modelo estima por marca y mes, no por distribuidor y SKU como enuncia el objetivo específico 3. Con distribuidor × SKU × mes solo el 0,9 % de las celdas tiene dato, frente al 68,0 % de marca × mes.
- Sesgo geográfico medido: al asignar la tasa de la marca sin mirar el destino, subestima entre 10 y 13 puntos a ciudades intermedias (Machala +0,134, Ambato +0,117). El MAPE agregado no lo revela.
- Error concentrado: julio de 2026 aporta 193 de las 369 unidades de error de los nueve meses, por modelos recién lanzados que no rotan en sus primeros 60 días.
- Datos personales: el módulo de seudonimización (HMAC-SHA256) está implementado y su equivalencia verificada con una clave de prueba (13 de 13 comprobaciones). Su aplicación a los datos del equipo con la clave definitiva queda pendiente, y los nombres de bodega siguen en claro. El modelo final opera sobre el panel agregado, que no contiene identificadores.