Reporte de interpretabilidad y ética

Modelo de predicción de devoluciones de inventario de equipos móviles

Grupo 5 · Maestría en Inteligencia Artificial Aplicada · Universidad de Las Américas
Guaján Perugachi Jimmy Israel · Martínez Ortega Jorge Washington · Vásquez Chávez Marco Vinicio

1. Descripción del modelo evaluado

Modelos analizados. Se interpretan los tres candidatos comparados en el proyecto: el modelo seleccionado, una regresión de Poisson con offset de exposición —E[devoluciones] = unidades en riesgo × tasa(marca)—, y los dos ensambles de árboles comprometidos en el capstone, Random Forest y XGBoost.

Objetivo dentro del proyecto. Predecir el volumen mensual de devoluciones por marca para una operadora de telefonía en Ecuador. Una devolución es una unidad que cumple sesenta días desde su despacho sin salir del canal; la definición se validó contra listados del área de planificación con un 99,75 % de coincidencia.

Conjunto de datos del análisis. Panel de 319 filas (marca × mes) construido desde 14 millones de registros de inventario diario y 6,4 millones de despachos. La interpretabilidad se calcula sobre el conjunto de prueba —enero a septiembre de 2026—, que ningún modelo vio durante el entrenamiento. La auditoría de equidad usa los 7.551 periodos individuales de esos nueve meses, con su ciudad y distribuidor de destino.

2. Análisis de interpretabilidad

Se aplicó SHAP (TreeExplainer) sobre los dos ensambles, no sobre uno solo, para que el resultado no dependiera de la elección de modelo.

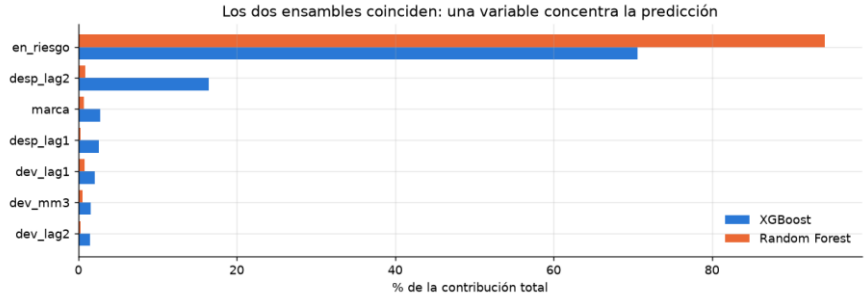


Figura 1. Importancia SHAP sobre el conjunto de prueba. Azul: XGBoost. Naranja: Random Forest.

Variable	XGBoost	Random Forest	Qué mide
en_riesgo	**70,6 %**	**94,2 %**	**unidades expuestas al cierre del mes anterior**
desp_lag2	16,5 %	0,9 %	despachos de hace dos meses
marca	2,8 %	0,7 %	Samsung, Honor, Apple…
resto (8 variables)	10,1 %	4,2 %	rezagos, medias móviles, estacionalidad

No se utilizó LIME: el modelo seleccionado es aditivo en escala logarítmica —log E[y] = log(exposición) + log λ(marca)—, de modo que su descomposición es exacta y una aproximación local no añadiría información. SHAP se aplica a los ensambles, que sí son cajas negras.

Patrones observados

- Una sola variable concentra la predicción, y los dos ensambles coinciden pese a ser familias distintas. Random Forest lo señala con más fuerza (94,2 %) que XGBoost (70,6 %).
- La diferencia entre ambos es explicable: XGBoost usa submuestreo de columnas (colsample_bytree = 0,8), de modo que en uno de cada cinco árboles no dispone de en_riesgo y recurre a desp_lag2, que es información redundante —las unidades despachadas hace dos meses son justamente las que ahora vencen—.
- La relación es multiplicativa y monótona: a mayor exposición, mayor predicción, en proporción aproximadamente constante dentro de cada marca.

Coherencia con el problema organizacional. El hallazgo es consistente con la operación real: lo que determina las devoluciones de un mes es cuántas unidades están a punto de cumplir el umbral, no la historia agregada de la marca. Esta coherencia es precisamente lo que llevó a sustituir el ensamble por un modelo de un parámetro por marca. **La técnica de explicabilidad no se limitó a describir el modelo: redirigió la decisión de modelado.**

3. Riesgos éticos identificados

3.1 Sesgo geográfico sistemático, medido

El modelo asigna la tasa de conversión de la marca con independencia del destino. Se auditó si eso trata por igual a todas las ciudades, comparando la tasa real de cada una con la que el modelo le asigna.

Ciudad	Unidades	Tasa real	Tasa del modelo	Desviación
Guayaquil	1.798	0,691	0,715	−0,024
Quito	2.965	0,701	0,721	−0,020
Portoviejo	153	0,804	0,705	+0,099
Latacunga	512	0,812	0,710	+0,102
Ambato	387	0,829	0,712	+0,117
Machala	**384**	**0,833**	**0,699**	**+0,134**

El patrón es sistemático, no aleatorio. Las dos ciudades principales rotan más rápido y el modelo las sobreestima levemente; las ciudades intermedias retienen inventario más tiempo y el modelo las subestima entre 10 y 13 puntos. Por distribuidor la dispersión es aún mayor: de −0,183 a +0,176 sobre 37 destinos con volumen suficiente. **Un MAPE agregado del 4,1 % convive con desviaciones de trece puntos entre territorios.**

3.2 Datos personales e identificativos

El reporte de despachos contiene IMEI, ICCID, número telefónico, RUC, razón social y dirección física del punto de venta. El pipeline descarta el teléfono y la dirección, pero conserva en claro 264.233 IMEI, 36.734 ICCID y 586 RUC en los archivos procesados. El capstone comprometió seudonimización bajo la LOPDP y esa medida aún no está implementada: las carpetas de origen se excluyen del control de versiones y el repositorio es privado, lo que mitiga la exposición pero no sustituye a la seudonimización.

3.3 Riesgo de uso indebido

El modelo predice que el inventario no rota, no que el distribuidor rinda mal. La distinción es crítica si la predicción se usara para asignar cupos, recortar crédito o evaluar al canal. El análisis de julio de 2026 lo demuestra: el 60 % del grupo expuesto de Honor eran 495 unidades de un mismo lanzamiento que no rotó, y esa decisión de surtido fue de la operadora, no del distribuidor. Atribuir ese resultado al punto de venta sería injusto y además incorrecto.

3.4 Opacidad y sesgos en los datos

- Opacidad: el modelo seleccionado son seis números —una tasa por marca— y es auditable sin herramientas. El riesgo aparecería si se sustituyera por el ensamble: seiscientos árboles tomando decisiones que afectan a terceros exigirían explicabilidad permanente, no puntual.
- Exclusiones que pueden sesgar: se descarta el 17 % de los periodos por no tener despacho asociado y el 8,2 % de unidades no rastreables. Un caso detectado —544 unidades a un cliente institucional, todas con idéntica permanencia— habría generado un destino con tasa del 100 %.
- Cobertura desigual: 1.031 unidades del conjunto de prueba carecen de ciudad registrada, lo que impide auditar su trato.

4. Interpretación de los hallazgos clave

Variable	Dirección y magnitud	Relación con el problema organizacional
en_riesgo	Positiva y casi lineal. Aporta el 70,6 % (XGBoost) y el 94,2 % (Random Forest) de la contribución. Correlación de 0,982 con el resultado.	Es la cola de vencimientos ya formada: planificación puede contarla al cierre de cada mes sin estimarla.
marca	Modula la tasa entre 0,59 (Honor) y 0,85 (Motorola). Magnitud baja en SHAP porque actúa sobre la exposición, no de forma aditiva.	Explica por qué dos distribuidores con el mismo volumen expuesto devuelven cantidades distintas.
desp_lag2	Positiva, 16,5 % en XGBoost y 0,9 % en Random Forest. La discrepancia revela redundancia, no un segundo factor.	Confirma el mecanismo: lo despachado hace dos meses es lo que ahora cumple el umbral.

La lectura conjunta es que el fenómeno tiene una causa dominante y medible, lo que hace el problema abordable con un modelo simple y auditable —una condición favorable para su uso responsable en decisiones de compra—.

5. Estrategias de mitigación

Riesgo	Acción concreta
Sesgo geográfico	Incorporar la ciudad o el tipo de punto de venta como dimensión del panel, con el mismo encogimiento jerárquico ya empleado para las marcas (k = 300), de modo que los destinos con poco volumen hereden la tasa global en lugar de seguir su ruido.

Riesgo	Acción concreta
Sesgo invisible en el agregado	Reportar el MAPE desagregado por ciudad junto al agregado en cada ejecución. El indicador global no habría revelado desviaciones de trece puntos.
Datos personales	Aplicar la seudonimización comprometida: hash estable sobre IMEI e ICCID y alias por distribuidor. El Plan Capstone ya constata que el cruce de inventario y el cálculo de permanencia funcionan igual sobre valores hasheados.
Uso indebido	Documentar en el entregable al cliente que la predicción no mide desempeño del distribuidor, y condicionar cualquier uso evaluativo a incorporar quién decidió el surtido.
Opacidad futura	Si se adoptara un ensamble, fijar como requisito el reporte SHAP por predicción, no solo global.

Limitaciones explícitas del sistema. El horizonte es de un mes; el criterio de error se cumple en media y uno de veintiún orígenes evaluados lo supera; la varianza observada es nueve veces la teórica, por lo que las predicciones deben comunicarse como rango y no como valor puntual; y el modelo no distingue productos dentro de una marca, que es el origen del error documentado.

6. Aprendizajes derivados del análisis

- Qué reveló sobre el comportamiento real. Que el modelo no aprendía un patrón complejo sino a contar una exposición y multiplicarla por una tasa. Lo que parecía capacidad del ensamble era la estructura del problema.
- Qué supuesto se cuestionó. El capstone sostenía, con base en la literatura, que los ensambles superan a los métodos clásicos cuando hay múltiples variables y relaciones no lineales. SHAP mostró que esa condición no se cumple en estos datos, y el instrumento previsto para explicar terminó redirigiendo la decisión de modelado.
- Qué supuesto se confirmó. Que la explicabilidad era necesaria: sin ella se habría entregado un ensamble que funciona por razones que nadie habría verificado.
- El aprendizaje de mayor alcance. Una métrica agregada puede ocultar un trato desigual. El 4,1 % global convive con una desviación de trece puntos entre Quito y Machala, y solo una auditoría por grupo lo hace visible.

7. Propuestas de ajuste al modelo

#	Ajuste propuesto	Qué hallazgo lo motiva
1	Añadir el destino —ciudad o tipo de punto de venta— como dimensión, con encogimiento jerárquico hacia la tasa global.	La desviación medida de −0,024 a +0,134 entre ciudades.
2	Incorporar atributos de producto que persistan entre generaciones: antigüedad en el catálogo, precio y gama. No el identificador del modelo, que deja de existir al descontinuarse.	El error se concentra en lanzamientos que no rotan: 169 de 171 iPhone 17 Pro retenidos en septiembre.
3	Añadir a la rutina de evaluación el MAPE por ciudad y por distribuidor, además del agregado.	El indicador global no reveló el sesgo territorial.
4	Sustituir IMEI, ICCID y RUC por identificadores hasheados en la capa procesada.	264.233 IMEI y 586 RUC en claro, frente al compromiso de seudonimización.
5	Entregar las predicciones como intervalo quasi-Poisson y no como valor puntual.	Sobredispersión $\phi = 8{,}9$: los intervalos sin corregir cubren el 57 % en lugar del 95 %.