Universidad de Las Américas

Facultad de Ingeniería y Ciencias Aplicadas

Maestría en Inteligencia Artificial Aplicada

Modelo de Predicción de Devoluciones de Inventario y el Ajuste de la Demanda Neta de SIMs y Equipos Móviles en una Empresa Líder de Telefonía Celular y Telecomunicaciones con Presencia en Ecuador

Guaján Perugachi Jimmy Israel

Martínez Ortega Jorge Washington

Vásquez Chávez Marco Vinicio

Nombres y Apellidos del guía

Agosto 2026

Quito, Ecuador

Contenido

Índice de ilustraciones 2

Índice de tablas 2

Resumen 3

Abstract 4

1. Introducción 5

1.1. Identificación y descripción del problema o necesidad 5

1.2. Causas principales 5

1.3. Consecuencias del problema 6

1.4. Descripción de la organización 7

1.4.1. Misión / Propósito 8

1.4.2 Visión 8

1.4.3. Estructura Organizacional 8

1.4.4. Segmento de mercado 8

1.4.5. Mercado objetivo 9

2. Análisis de posibles soluciones 10

2.1 Identificación y selección de la mejor solución 10

2.2 Propuesta A: Modelo de predicción por lotes (batch) con reporte analítico 10

2.3 Propuesta B: Plataforma de predicción con integración automática y reentrenamiento continuo (MLOps) 11

2.4 Criterios de comparación (ISO/IEC 25010) 11

2.5 Viabilidad técnica y operativa 13

2.6 Viabilidad de tiempo y recursos 13

2.7 Análisis de alternativas: desarrollar vs. adquirir una solución existente 13

2.8 Impacto del proyecto en la sociedad 14

3 Objetivos 16

3.1 Objetivo General 16

3.2 Objetivos Específicos 17

4 Alcance 17

4.1 Alcance de la solución seleccionada 17

4.2 Limitaciones y restricciones del proyecto 18

5 Planificación y costos del proyecto 19

5.1 Cronograma del proyecto 19
6 Costos del Proyecto 21
7 Descripción de estudios realizados 22
8 Desarrollo del proyecto 24
8.1 Diseño de la solución 24
8.2 Desarrollo de la solución 25
8.3 Resultados y Discusión. 25
8.4 Implicaciones éticas 25
9 Conclusiones y Recomendaciones 25
10 Trabajo futuro 26
11 Referencias bibliográficas 26
12 Anexos 28

Índice de ilustraciones

Ilustración 1 Diagrama causa-efecto (Ishikawa) del problema identificado. 6
Ilustración 2 Organigrama básico del Operador de Telefonía Cliente 8
Ilustración 3 Modelo de contexto (Nivel 1) – Propuesta A 11
Ilustración 4 Modelo de contexto (Nivel 1) – Propuesta B 11
Ilustración 5 Diagrama de Gantt del cronograma propuesto 21

Índice de tablas

Tabla 1 Composición del inventario por segmento de producto. Fuente: datos operativos del Operador de Telefonía Cliente 7
Tabla 2 Criterios de Evaluación de Propuestas (ISO/IEC 25010) 12
Tabla 3 Evaluación de Alternativas Desarrollar vs. Adquirir 14
Tabla 4Cronograma de Proyecto 19
Tabla 5 Estimación de costos por fase del proyecto (CRISP-ML(Q)) 22

Resumen

[Esta sección incluye una síntesis del trabajo, su extensión no deberá ser mayor a 350 palabras. Deberá dar una idea completa del trabajo, resaltando solo lo esencial: objetivos, métodos y/o metodología, resultados y conclusiones. También se debe colocar al final las palabras clave.]



Abstract

[Esta sección incluye el resumen en idioma inglés.]

1. Introducción

1.1. Identificación y descripción del problema o necesidad

Una empresa líder en el servicio de telefónica celular y transmisión de datos e Internet con presencia en Ecuador utiliza actualmente un método semiautomático de proyección de demanda para estimar sus necesidades de abastecimiento, principalmente en función de los pedidos y las ventas históricas de los dos últimos años gestionadas por sus distribuidores, sin incorporar de forma sistemática y anticipada el comportamiento de las devoluciones de inventario. Como resultado, la proyección de demanda no refleja con precisión la demanda neta real (pedidos menos devoluciones esperadas), lo que genera desviaciones entre lo proyectado y lo efectivamente consumido en el mercado. Esta limitación contribuye a la acumulación de existencias de SIMs y equipos móviles en bodega —con el consecuente riesgo de obsolescencia tecnológica y comercial de los productos— que al momento se ubica en un promedio de 5.9% considerando el inventario total frente a una meta esperada del 2.9% (métricas evaluadas con cortes semestral y anual por parte de la empresa y compartidas en entrevista de relevamiento) y, simultáneamente, dificulta que la empresa oriente su inventario hacia los distribuidores con mayor probabilidad real de colocación, lo cual afecta su objetivo estratégico de incrementar la participación de mercado en líneas celulares mediante la colocación de SIMs y la renovación del parque de equipos de sus clientes.

1.2. Causas principales

El problema identificado corresponde a la desviación entre la demanda proyectada y la demanda neta real de SIMs y equipos móviles, situación que fue analizada mediante un diagrama causa-efecto (Ishikawa). Entre las causas más relevantes se identificaron, en la categoría de método, la ausencia de un mecanismo que incorpore las devoluciones esperadas al cálculo de la demanda neta y el hecho de que la proyección semiautomática actual no cuenta con un componente predictivo de devoluciones; en la categoría de datos e información; en la categoría de distribuidores, se observaron patrones que denotan pedidos excesivos (sobrepedidos) de forma sistemática a nivel de algunos de ellos.; y en la categoría de tecnología, se identificó la falta de una herramienta analítica dedicada a la predicción de devoluciones. A continuación, se presenta el diagrama correspondiente.

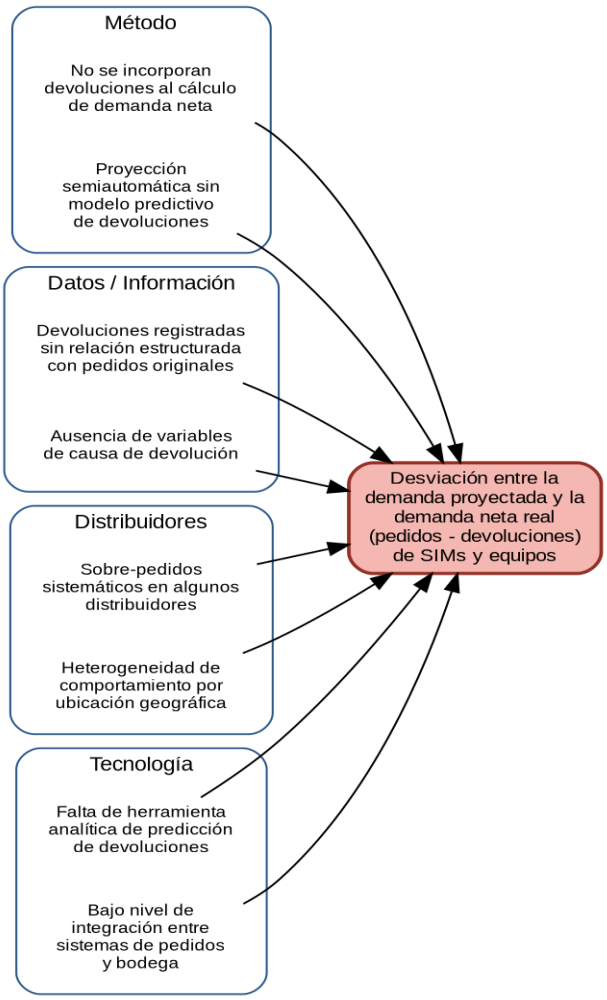


Ilustración 1 Diagrama causa-efecto (Ishikawa) del problema identificado.

1.3. Consecuencias del problema

Esta situación genera un impacto operativo y comercial significativo y cuantificable. Cualitativamente, el equipo de planificación de demanda reporta baja visibilidad sobre el volumen de inventario que retornará a bodega en los siguientes ciclos, lo que limita su capacidad de reasignar oportunamente el stock hacia distribuidores con mayor probabilidad de venta. Cuantitativamente, la magnitud del inventario gestionado por la empresa es considerable: 19 SKUs activos de SIMs y 250 SKUs activos de equipos móviles, que en conjunto representan 269 SKUs, con un stock promedio de aproximadamente 2.000.000 de unidades de SIMs y 11.000 unidades de equipos, y una valoración promedio total de USD 4'477.924,01 (Tabla 1).

Tabla 1 Composición del inventario por segmento de producto. Fuente: datos operativos del Operador de Telefonía Cliente

Segmento	N.° SKUs	Stock promedio (unidades)	Valoración promedio (USD)	Valor unitario promedio (USD)
SIM Cards	19	2.000.000	$ 902.876,00	$ 0,45
Equipos Móviles	250	11.000	$ 3.575.048,01	$ 325,00 aprox.
TOTAL	**269**	—	**$ 4.477.924,01**	—

Sobre esta base de inventario, la empresa reporta —según métricas evaluadas con cortes semestral y anual, y compartidas en la entrevista de relevamiento— un nivel de obsolescencia promedio del 5,9% del inventario total, frente a una meta esperada del 2,9%. Esta brecha de 3,0 puntos porcentuales equivale a aproximadamente USD 134.337,72 en inventario adicional expuesto a riesgo de obsolescencia (5,9% de USD 4'477.924,01 ≈ USD 264.197,52 en riesgo actual, frente a USD 129.859,82 bajo la meta esperada del 2,9%), monto que respalda cuantitativamente la necesidad de un modelo predictivo que anticipe el comportamiento de las devoluciones. De no atenderse, la desviación entre demanda proyectada y demanda neta real continuará incrementando el riesgo de obsolescencia tecnológica y comercial de los productos en bodega, afectando la eficiencia del capital invertido en existencias y limitando el crecimiento de la participación de mercado que la empresa persigue mediante la colocación de nuevas líneas y la renovación de equipos, además de dificultar que la empresa oriente su inventario hacia los distribuidores con mayor probabilidad real de colocación.

Nota: el problema descrito ocurre en el área de planificación de demanda y gestión de inventarios del Operador de Telefonía, en coordinación con su red nacional de distribuidores.

1.4. Descripción de la organización

La organización es una empresa líder a nivel mundial de telefonía celular y telecomunicaciones, con operación en Ecuador, que mantiene una red de distribuidores autorizados localizados en las distintas provincias del país. La compañía gestiona, desde una bodega central, las existencias de tarjetas SIM y equipos de telefonía móvil que abastecen a dicha red de distribuidores, quienes a su vez realizan pedidos periódicos, generan ventas a clientes finales y, en determinados casos, efectúan devoluciones de inventario hacia la bodega central. Para sostener este flujo, la empresa cuenta con un método semiautomático de proyección de demanda que estima, a partir del

comportamiento histórico de pedidos y ventas, las cantidades de SIMs y equipos que deben reponerse en cada ciclo de abastecimiento.

1.4.1. Misión / Propósito

“Construir autopistas digitales que conectan personas, transforman vidas y desarrollan comunidades.”

1.4.2 Visión

La visión de la empresa se enfoca en “impulsar la inclusión digital y el desarrollo de las comunidades mediante servicios de telecomunicaciones y soluciones digitales innovadoras, promoviendo el progreso económico y social en los países donde opera”.

1.4.3. Estructura Organizacional

Respecto de la estructura interna de la empresa, los misma presenta las siguientes áreas:

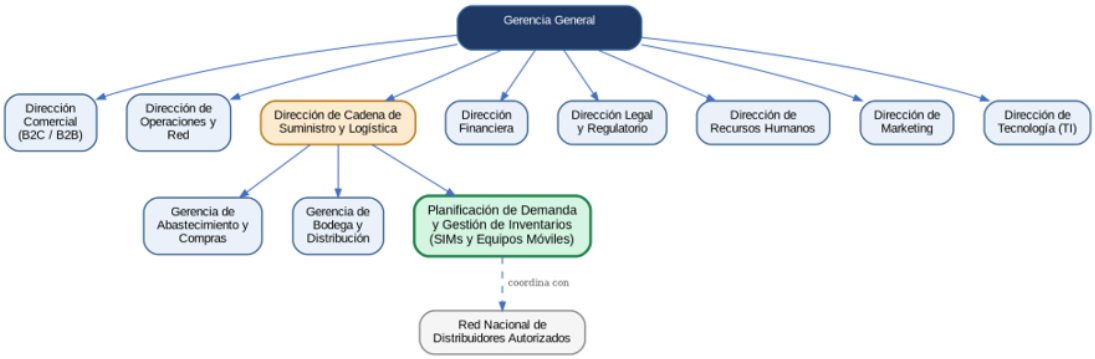


Ilustración 2 Organigrama básico del Operador de Telefonía Cliente

En base al diagrama macro anterior, podemos indicar que el proyecto beneficia al área de planificación de demanda y gestión de inventarios de la empresa.

1.4.4. Segmento de mercado

La empresa opera principalmente en el **sector de telecomunicaciones y servicios digitales**, atendiendo distintos segmentos de mercado:

1. **Mercado masivo (B2C)**
   - Usuarios de telefonía móvil prepago y pospago.
   - Clientes de internet móvil.
   - Personas y familias que requieren servicios de conectividad y comunicación.
2. **Empresas (B2B)**
   - Pequeñas, medianas y grandes empresas.

- Servicios de conectividad corporativa, datos, soluciones en la nube y herramientas digitales para negocios.

3. **Sector gubernamental e institucional**

    - Entidades públicas y organizaciones que requieren infraestructura y servicios de telecomunicaciones.

1.4.5. Mercado objetivo

El mercado objetivo de la empresa se compone de personas y organizaciones que buscan mantener acceso confiable a servicios de comunicación digital, Internet y tecnologías que faciliten sus actividades personales, comerciales y productivas. Cubre zonas urbanas y áreas lejanas con necesidad de inclusión digital.

Entre los productos que ofrece la empresa están, **telecomunicaciones y conectividad digital** dirigidos a personas, hogares y empresas como son:

a. Telefonía móvil

- Planes prepagos.
- Planes pospago.
- Llamadas nacionales e internacionales.
- Mensajería SMS.
- Servicios de roaming internacional.

b. Internet móvil

- Paquetes de datos para navegación.
- Planes de internet para teléfonos inteligentes.
- Acceso a redes 4G/LTE y expansión de infraestructura digital.

c. Venta de dispositivos

- Smartphones.
- Tablets.
- Módems y equipos de conectividad.
- Accesorios tecnológicos.

d. Servicios digitales para clientes

- Aplicaciones de autogestión.
- Consulta y pago de servicios.
- Compra de paquetes y recargas.
- Atención al cliente digital.

e. Soluciones para empresas (B2B)

- Internet corporativo.
- Redes de datos y conectividad empresarial.

- Soluciones en la nube (Cloud).
- Ciberseguridad.
- Herramientas de colaboración y transformación digital.
- Servicios administrados para empresas.

f. Servicios para instituciones y gobierno

- Conectividad y transmisión de datos.
- Soluciones tecnológicas para entidades públicas.
- Infraestructura de telecomunicaciones.

2. Análisis de posibles soluciones

2.1 Identificación y selección de la mejor solución

A continuación, se presentan dos propuestas de solución para el desarrollo del modelo de predicción de devoluciones de inventario, cada una con su respectivo modelo de contexto de nivel 1, con el fin de compararlas de forma objetiva mediante criterios sustentados en la norma ISO/IEC 25010 (2023) y seleccionar la alternativa más adecuada para el alcance de este proyecto de titulación.

2.2 Propuesta A: Modelo de predicción por lotes (batch) con reporte analítico

Objetivo: predecir mensualmente el volumen esperado de devoluciones por distribuidor y SKU, integrando los resultados como una capa analítica adicional al proceso de proyección de demanda vigente, sin modificar el flujo operativo actual.

Alcance funcional: cubre la ingesta de datos de pedidos, ventas y devoluciones desde el ERP corporativo; el entrenamiento y ejecución del modelo predictivo; y la publicación de resultados en un tablero de consulta para el equipo de planificación de demanda, quien ajusta manualmente la proyección con base en dicha información.

Arquitectura propuesta: arquitectura de procesamiento por lotes (batch), con extracción de datos hacia un repositorio de trabajo, ejecución del modelo y publicación de resultados en un tablero de reporte.

Tecnologías: Python, scikit-learn, XGBoost, un repositorio de datos de prueba y Power BI para la visualización de resultados.

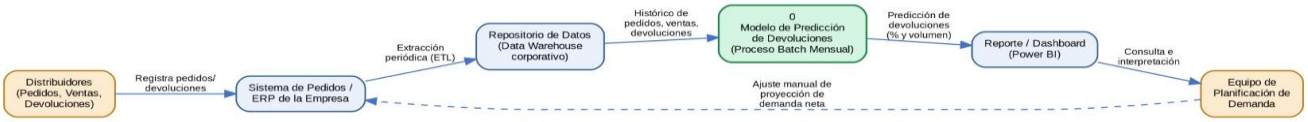


Ilustración 3 Modelo de contexto (Nivel 1) – Propuesta A

2.3 Propuesta B: Plataforma de predicción con integración automática y reentrenamiento continuo (MLOps)

Objetivo: predecir de forma casi continua el volumen esperado de devoluciones, integrando automáticamente los resultados al sistema de planificación de demanda mediante una API, con reentrenamiento periódico del modelo a partir de nuevos datos.

Alcance funcional: cubre la ingesta casi en tiempo real de eventos de pedidos, ventas y devoluciones; el procesamiento en una plataforma de datos en la nube; el reentrenamiento continuo del modelo bajo un enfoque de MLOps; y la integración automática de las predicciones al sistema de planificación de demanda, además de un tablero interactivo con explicabilidad del modelo (SHAP).

Arquitectura propuesta: arquitectura basada en microservicios, con un pipeline de datos en la nube (data lake / lakehouse), un servicio de reentrenamiento continuo y una API REST de predicción integrada al sistema de planificación de demanda.

Tecnologías: Python, XGBoost, SHAP, una plataforma de datos en la nube (p. ej., Azure Databricks), contenedores para el despliegue del microservicio y un tablero interactivo (p. ej., Power BI o un dashboard web).

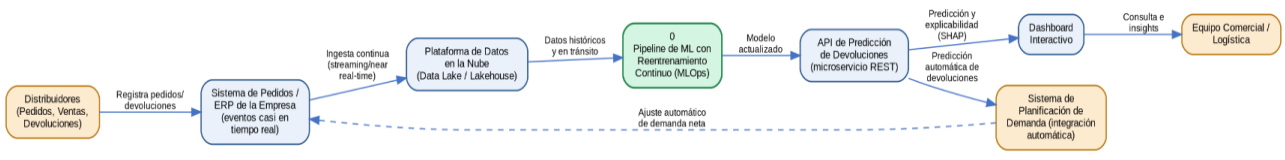


Ilustración 4 Modelo de contexto (Nivel 1) – Propuesta B

2.4 Criterios de comparación (ISO/IEC 25010)

Para comparar objetivamente ambas propuestas se emplearon características del modelo de calidad de producto de software ISO/IEC 25010 (2023). Los pesos relativos se definieron priorizando la fiabilidad y la mantenibilidad (20 % cada

una), dado que el proyecto busca una integración de bajo riesgo con el proceso de proyección de demanda actualmente en producción, seguidas de la funcionalidad (20 %), la seguridad (15 %) —relevante por tratarse de información comercial de distribuidores—, la eficiencia de desempeño (10 %), la usabilidad (10 %) y la portabilidad (5 %), de menor criticidad al tratarse de un despliegue interno único.

Tabla 2 Criterios de Evaluación de Propuestas (ISO/IEC 25010)

Criterio (ISO/IEC 25010)	Peso	Propuesta A	Propuesta B	Justificación breve
Adecuación funcional	20%	4	5	B ofrece integración automática y predicción casi continua
Fiabilidad	20%	5	3	A es más estable al no depender de integración en tiempo real
Mantenibilidad	20%	5	3	A requiere menor especialización (MLOps) para su mantenimiento
Seguridad	15%	4	4	Ambas requieren control de acceso equivalente a los datos
Eficiencia de desempeño	10%	3	4	B procesa datos con menor latencia
Usabilidad	10%	4	4	Ambas ofrecen tableros de consulta comprensibles
Criterio (ISO/IEC 25010)	**Peso**	**Propuesta A**	**Propuesta B**	**Justificación breve**
Portabilidad	5%	3	4	B es más portable por su diseño en contenedores/nube
Total (100%)	**100%**	**4.25**	**3.80**	

De acuerdo con la matriz de evaluación, la Propuesta A obtiene la mayor calificación ponderada (4.25 sobre 5.00), principalmente por su mayor fiabilidad y mantenibilidad, características priorizadas dado el objetivo de integrar la predicción de devoluciones como una capa analítica de bajo riesgo sobre el proceso de proyección de demanda que la empresa mantiene actualmente en producción. Por lo tanto, se selecciona la Propuesta A (modelo de predicción por lotes con reporte analítico) como solución para el alcance de este proyecto de

titulación, dejando planteada la evolución hacia una arquitectura similar a la Propuesta B (integración automática y reentrenamiento continuo) como una fase posterior, una vez validado el valor analítico del modelo en producción.

2.5 Viabilidad técnica y operativa

Herramientas y tecnologías: Python, librerías de código abierto (scikit-learn, XGBoost, SHAP, pandas), y el repositorio de datos corporativo con el que ya cuenta la empresa.

Acceso a datos, procesos y usuarios: la empresa dispone de información histórica de existencias de SIMs y equipos, pedidos, ventas y devoluciones por distribuidor, lo que resulta suficiente para el entrenamiento y validación del modelo.

Competencias del equipo desarrollador: el equipo de titulación cuenta con formación en ciencia de datos e inteligencia artificial aplicada, con experiencia en los lenguajes y librerías propuestos.

Disponibilidad de la organización: la empresa ha mostrado interés en la validación del proyecto como caso de aplicación, facilitando el acceso a información histórica (anonimizada o agregada según las políticas de confidencialidad que se acuerden) y a los equipos de planificación de demanda para su retroalimentación.

2.6 Viabilidad de tiempo y recursos

Tiempo estimado de desarrollo: doce semanas, distribuidas conforme a los objetivos específicos planteados en la sección 4.

Recursos requeridos: acceso a los datos históricos de la empresa, un equipo de cómputo con capacidad para el entrenamiento de modelos de aprendizaje automático y herramientas de código abierto, sin requerir licenciamiento adicional.

Factibilidad con medios disponibles: dado que la Propuesta A no requiere infraestructura de nube especializada ni integración en tiempo real, es factible desarrollarla con los medios de cómputo y de datos disponibles para el equipo de titulación.

2.7 Análisis de alternativas: desarrollar vs. adquirir una solución existente

En el mercado existen plataformas comerciales de planeación de demanda y cadena de suministro (por ejemplo, SAP Integrated Business Planning, o9 Solutions o Blue Yonder) que incluyen módulos de gestión de devoluciones. Sin embargo, estas soluciones están orientadas a procesos genéricos de planeación empresarial, requieren licenciamiento recurrente e implementaciones prolongadas, y no necesariamente se ajustan a la granularidad de datos por

distribuidor manejada por la empresa en el contexto ecuatoriano. A continuación, se presenta la comparación entre desarrollar una solución propia y adquirir una plataforma comercial.

Tabla 3 Evaluación de Alternativas Desarrollar vs. Adquirir

Criterio	Desarrollar solución propia (Propuesta A)	Adquirir/licenciar plataforma comercial
Costo inicial	Bajo, basado en herramientas de código abierto y recursos del equipo de titulación	Alto, por licenciamiento e implementación especializada
Costo a largo plazo	Menor, sin licenciamiento recurrente	Creciente, por renovación de licencias y soporte
Tiempo de implementación	Compatible con el cronograma de catorce semanas del proyecto	Prolongado, típicamente varios meses
Flexibilidad y personalización	Alta, ajustable a la granularidad de datos de distribuidores en Ecuador	Limitada por el diseño estándar del proveedor
Control de datos	Total, dentro de la infraestructura de la empresa	Dependiente de las políticas del proveedor
Riesgos	Acotados al ser una capa adicional que no reemplaza el proceso vigente	Bajos en madurez del producto, pero altos en costo y en tiempo de adopción

Esta comparación respalda la decisión de desarrollar una solución propia (Propuesta A) para el alcance de este proyecto de titulación, dado su menor costo, su compatibilidad con el tiempo disponible y su capacidad de adaptarse a la granularidad de datos específica de la empresa, sin descartar la evaluación futura de plataformas comerciales como complemento una vez validado el valor del modelo desarrollado.

2.8 Impacto del proyecto en la sociedad

Con base en la magnitud del inventario gestionado (269 SKUs, USD 4'477.924,01 en valoración promedio) y en la brecha de obsolescencia identificada (5,9% actual frente a una meta del 2,9%, equivalente a un riesgo adicional de aproximadamente USD 134.337,72), a continuación, se analizan los beneficios esperados del proyecto para la organización y para la sociedad mediante un análisis PESTEL (Político, Económico, Social, Tecnológico, Ambiental y Ético).

Político

El proyecto se alinea con el marco regulatorio ecuatoriano vigente en materia de protección de datos personales, en particular con la Ley Orgánica de Protección

de Datos Personales (Asamblea Nacional del Ecuador, 2021), al contemplar desde su diseño la anonimización y el tratamiento agregado de la información de distribuidores. Esta alineación regulatoria reduce el riesgo legal de la empresa frente a auditorías o requerimientos de la Superintendencia de Protección de Datos Personales, y fortalece la posición de la compañía frente a organismos de control del sector de telecomunicaciones. Adicionalmente, la adopción de un marco de calidad reconocido internacionalmente como ISO/IEC 25010 (2023) para evaluar la solución técnica aporta un estándar de gobernanza que facilita futuras auditorías internas y externas.

Económico

El beneficio económico es el más directamente cuantificable a partir de los datos operativos disponibles. Reducir la brecha de obsolescencia del 5,9% actual hacia la meta del 2,9% liberaría aproximadamente USD 134.337,72 en capital actualmente inmovilizado en inventario con riesgo de obsolescencia, recursos que podrían reorientarse hacia la adquisición de SKUs de mayor rotación o hacia otras inversiones comerciales. Este hallazgo es consistente con la literatura revisada: Ambilkar et al. (2022) documentan que la gestión deficiente de devoluciones genera costos significativos de capital inmovilizado en las cadenas de suministro, mientras que Goulart et al. (2026) evidencian, en un caso empresarial similar de un distribuidor con múltiples SKUs, que un modelo de pronóstico basado en aprendizaje automático puede reducir sustancialmente el error de previsión y mejorar la eficiencia de reposición de inventario sin inversión en infraestructura especializada. A esto se suma el beneficio de mejorar la colocación de SIMs y la renovación de equipos hacia los distribuidores con mayor probabilidad real de venta, lo que respalda directamente el objetivo estratégico de crecimiento en participación de mercado de la empresa.

Social

Una mejor orientación del inventario hacia los distribuidores con mayor probabilidad de colocación fortalece la relación comercial y la satisfacción de la red de distribuidores autorizados a nivel nacional, muchos de los cuales son pequeños y medianos negocios cuya sostenibilidad depende de la disponibilidad oportuna de stock. Adicionalmente, al reducir quiebres de stock y sobreabastecimiento, el proyecto contribuye indirectamente a sostener el acceso a líneas móviles y equipos en zonas del país con menor cobertura, lo cual es relevante considerando que, según GSMA Intelligence (2024), persisten brechas de conectividad y adopción de banda ancha móvil en varios mercados de Ecuador y la región. Un mejor abastecimiento de la red de distribución es, en ese sentido, un habilitador indirecto de la inclusión digital de los usuarios finales.

Tecnológico

El proyecto introduce en la organización capacidades de aprendizaje automático supervisado, explicabilidad de modelos (SHAP) y prácticas de MLOps (Kreuzberger et al., 2023) que actualmente no forman parte del proceso semiautomático de proyección de demanda. Esto constituye un beneficio tecnológico que trasciende el alcance inmediato del proyecto, ya que sienta las

bases metodológicas y de infraestructura (versionado de datos y modelos, monitoreo continuo) que la empresa podría reutilizar en futuras iniciativas de analítica avanzada, incluyendo la evolución hacia la Propuesta B descrita en la sección 7.2. Asimismo, la incorporación de explicabilidad (Kosasih et al., 2024) mejora la capacidad organizacional de auditar y confiar en modelos de IA aplicados a decisiones comerciales.

Ambiental

Reducir la obsolescencia de SIMs y equipos móviles tiene un beneficio ambiental directo, al disminuir la generación de residuos electrónicos (e-waste) asociados a productos que permanecen en bodega hasta perder vigencia comercial o tecnológica y terminan descartándose. Srivastav et al. (2023) señalan que la aplicación de técnicas de inteligencia artificial y aprendizaje automático a la gestión de inventario contribuye a una economía circular más sostenible en el sector electrónico, al permitir una mejor planificación que reduce tanto el sobre-stock como el desperdicio de productos no comercializados. En el caso de este proyecto, cada punto porcentual de reducción en la tasa de obsolescencia representa una disminución proporcional en el volumen de SIMs y equipos que eventualmente requerirían disposición final, alineando el proyecto con los principios de economía circular y con las metas de sostenibilidad ambiental de la empresa.

Ético

El uso de datos históricos de distribuidores para entrenar modelos que orienten decisiones comerciales conlleva consideraciones éticas que el proyecto aborda explícitamente desde su diseño. Siguiendo a Mehrabi et al. (2021), se auditará la representatividad de los datos por distribuidor y zona geográfica para evitar que el modelo penalice sistemáticamente a distribuidores con menor volumen histórico de información, lo que podría profundizar inequidades existentes en la red de distribución. La incorporación de SHAP como mecanismo de explicabilidad refuerza este compromiso ético, al permitir que las decisiones comerciales derivadas del modelo sean auditables y justificables ante los propios distribuidores, en lugar de operar como una "caja negra" no transparente.

3 Objetivos

3.1 Objetivo General

Desarrollar mediante algoritmos de aprendizaje supervisado un modelo que prediga el volumen esperado de devoluciones de SIMs y equipos móviles mediante datos históricos de pedidos y ventas, para ajustar la demanda neta en una empresa de telefonía celular en Ecuador.

3.2 Objetivos Específicos

1. Analizar, los datos históricos de pedidos, ventas y devoluciones de SIMs y equipos móviles por distribuidor y zona geográfica de los últimos años, en base a ciclos de devolución, mediante estadística descriptiva y análisis exploratorio de datos (EDA), para identificar al menos dos variables con mayor relación con la ocurrencia de devoluciones y definir el alcance final de las variables predictoras del modelo.

2. Diseñar, la arquitectura de la solución de predicción de devoluciones mediante un modelo de contexto de nivel 1, un diagrama de flujo de datos y la definición del pipeline de extracción, transformación y carga (ETL) de la información de pedidos y devoluciones, en base a la información recibida a partir del repositorio de datos corporativo de la empresa.

3. Desarrollar un modelo predictivo utilizando regresión supervisada, configurando para ello Random Forest y XGBoost en Python, empleando librerías como scikit-learn, xgboost y SHAP, que estime el volumen esperado de devoluciones por distribuidor y SKU, garantizando la documentación completa del pipeline de entrenamiento y de las funcionalidades planificadas.

4. Evaluar e integrar, el modelo de predicción de devoluciones mediante métricas de desempeño de regresión (MAPE, MAE y RMSE), aplicando pruebas funcionales sobre un conjunto de validación independiente, asegurando un error porcentual absoluto medio (MAPE) máximo del 15 % y ajustando los hiperparámetros necesarios.

5. Implementar y validar, el modelo de predicción de devoluciones en un piloto controlado con un subconjunto de distribuidores, en base a la interpretación de los resultados y midiendo una reducción esperada de al menos el 10 % en la desviación entre la demanda proyectada y la demanda neta real.

4 Alcance

4.1 Alcance de la solución seleccionada

El problema organizacional en este proyecto consiste en la ausencia de un mecanismo predictivo que incorpore el volumen esperado de devolución de inventario de SIMs y equipos móviles al método semiautomático de proyección de demanda de una empresa líder de telefonía celular y telecomunicaciones con presencia en Ecuador, para ellos siguientes puntos clave:

a) **Tipo de datos:** el proyecto utilizará datos estructurados, tabulares, provenientes de los sistemas internos de la empresa (ERP y sistema de gestión de bodega), correspondientes al histórico de pedidos, ventas, devoluciones y existencias de SIMs y equipos móviles por distribuidor, complementados con datos de ubicación geográfica de cada distribuidor.

El origen es transaccional (registros por operación) y se prevé la anonimización o agregación de identificadores sensibles de distribuidores conforme a las políticas de confidencialidad y protección de datos personales aplicables en Ecuador (Ley Orgánica de Protección de Datos Personales), garantizando que la información utilizada para el entrenamiento no permita la identificación directa de clientes finales.

b) **Técnicas o modelos de IA potenciales:** con base en la evidencia revisada, se plantea el uso de Random Forest y XGBoost en su variante de regresión, orientada exclusivamente a estimar el volumen esperado de devolución, dado su desempeño superior documentado frente a métodos estadísticos clásicos en contextos similares (Mishra & Dutta, 2024; Nagadevi et al., 2025; Karl, 2024), y la incorporación de SHAP como mecanismo de explicabilidad (Arboleda-Flórez & Castro-Zuluaga, 2023; Kosasih et al., 2024). Todo el desarrollo se enmarcará en la metodología CRISP-ML(Q) (Studer et al., 2021), incorporando prácticas de MLOps (Kreuzberger et al., 2023) para el versionado de datos y modelos, y el monitoreo posterior al despliegue.
c) **Variables y métricas preliminares:** como variables predictoras se contemplan, a nivel de distribuidor y SKU, el historial de pedidos y ventas, la frecuencia y estacionalidad de pedidos, la ubicación geográfica y el volumen histórico de devolución. Como métricas de rendimiento se emplearán el error porcentual absoluto medio (MAPE), el error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE) para evaluar la precisión de la estimación del volumen esperado de devolución, en línea con los estudios revisados (Mishra & Dutta, 2024; Nagadevi et al., 2025; Goulart et al., 2026). Como métrica de interpretabilidad se utilizarán los valores SHAP para identificar las variables con mayor contribución a cada estimación individual de volumen, y como métrica de riesgo se dará seguimiento a la subestimación del volumen en los periodos de mayor devolución (error asimétrico hacia valores por debajo de lo real), dado su mayor impacto en la obsolescencia de inventario.
d) **Consideraciones sobre sesgos y equidad:** siguiendo a Mehrabi et al. (2021), durante la fase de análisis exploratorio de datos se evaluará explícitamente si el histórico disponible sobre-representa a determinados distribuidores, zonas geográficas o periodos, lo que podría sesgar el modelo hacia patrones no generalizables al conjunto completo de la red de distribución. Se documentará la distribución de las predicciones por zona geográfica para verificar que el modelo no penalice sistemáticamente a distribuidores de regiones con menor volumen histórico de datos, y se establecerá como buena práctica la revisión periódica de estas métricas de equidad como parte del monitoreo continuo (MLOps) del modelo en producción.

4.2 Limitaciones y restricciones del proyecto

El alcance de este documento se centra específicamente en la estimación cuantitativa del volumen de devolución (un problema de regresión), sin abordar la predicción de la probabilidad de devolución (un problema de clasificación). Con el fin de sustentar académica y técnicamente la solución propuesta, se

realizó una búsqueda bibliográfica sistemática, se elaboró una matriz de literatura con las fuentes más pertinentes, se desarrolló una síntesis crítica de las tendencias identificadas y se planteó una propuesta metodológica inicial coherente con la evidencia revisada.

5 Planificación y costos del proyecto

5.1 Cronograma del proyecto

El proyecto se desarrollará durante doce semanas, entre la primera semana de agosto y la última semana de octubre de 2026, organizadas conforme a las seis fases de la metodología CRISP-ML(Q): las fases 1 (Business & Data Understanding) y 2 (Data Engineering) se ejecutarán durante agosto, las fases 3 (ML Model Building) y 4 (Model Evaluation) durante septiembre, y las fases 5 (Model Deployment) y 6 (Monitoring and Maintenance) durante octubre. A continuación, se detalla el cronograma tentativo, incluyendo los hitos administrativos acordados con el cliente y las actividades de MLOps que acompañan cada fase.

Tabla 4Cronograma de Proyecto

Semana	Fase CRISP-ML(Q)	Actividades / Hitos	Actividades MLOps
Ago S1	1. Business & Data Understanding	Kickoff interno del equipo, revisión del alcance de la propuesta entregada. Hitos: OK apoyo cliente al proyecto (31 julio 2026), entrega de propuesta (2 ago 2026).	Definición de estructura del proyecto
Ago S2	1. Business & Data Understanding	Reunión formal de arranque con el cliente, identificación de fuentes de datos disponibles. Hito: aceptación del proyecto UDLA (8 ago 2026).	Definición del pipeline base en base a CRISC-ML(Q).
Ago S3	1. Business & Data Understanding	Entrevistas, exploración preliminar de fuentes, primer borrador de diccionario de datos. Hito: relevamiento de datos con el cliente (20 ago 2026).	Definición de herramienta de tracking de experimentos (MLflow). Creación del repositorio (Git); Definición del esquema de almacenamiento y versionado de datos (DVC o similar).

Semana	Fase CRISP-ML(Q)	Actividades / Hitos	Actividades MLOps
Ago S4	2. Data Engineering (Data Preparation)	Validación inicial de calidad de los datos recibidos e ingesta al repositorio. Hitos: revisión inicial de observaciones (25 ago); entrega de cronograma y respuesta a observaciones (26 ago); recepción de datos base (28 ago).	Configuración del entorno de desarrollo colaborativo y pipeline de CI. Ingesta versionada y validación automatizada de esquema (data validation).
Sep S1	2. Data Engineering (Data Preparation)	Limpieza de datos, tratamiento de valores atípicos/faltantes, unificación de fuentes (pedidos, ventas, devoluciones, ubicación de distribuidores).	Pipeline ETL reproducible y versionado (Airflow/Prefect); pruebas unitarias de transformación.
Sep S2	2. Data Engineering (Data Preparation)	Feature engineering (variables por distribuidor/zona/histórico) y partición train/validation/test. Entregable: dataset preparado.	Registro de linaje de datos y documentación de variables (feature store simplificado).
Sep S3	3. ML Model Building	Entrenamiento de modelos baseline: Random Forest y XGBoost (clasificación y regresión).	Tracking de experimentos (MLflow); registro de métricas y parámetros por corrida.
Sep S4	3. ML Model Building	Ajuste de hiperparámetros (Grid/Random Search y validación cruzada), selección del modelo candidato y análisis de explicabilidad (SHAP). Entregable: modelo candidato documentado.	Versionado de modelos (model registry); empaquetado del modelo (serialización/contenedor).
Oct S1	4. Model Evaluation	Evaluación con métricas de desempeño de regresión (MAPE, MAE y RMSE) sobre un conjunto de validación independiente.	Pruebas automatizadas del modelo (unit/integration tests de ML).
Oct S2	4. Model Evaluation	Ajuste final según resultados, validación con el equipo de planificación de demanda y verificación del MAPE máximo esperado (15%). Entregable: reporte de evaluación.	Checklist de aprobación del modelo (quality gate) previo al despliegue.

Semana	Fase CRISP-ML(Q)	Actividades / Hitos	Actividades MLOps
Oct S3	5. Model Deployment	Implementación en piloto controlado con un subconjunto de distribuidores, integración con el tablero (Power BI) y capacitación al equipo de planificación de demanda.	Despliegue vía pipeline CI/CD; registro (logging) de predicciones.
Oct S4	6. Monitoring and Maintenance	Configuración del monitoreo del modelo en el piloto, definición de la política de reentrenamiento futura, informe final y cierre del proyecto.	Alertas de data/concept drift; documentación del plan de reentrenamiento (roadmap hacia la Propuesta B).

A continuación, se presenta la representación gráfica del cronograma en formato de diagrama de Gantt, en la que se visualiza la duración de cada fase de CRISP-ML(Q) y los hitos/entregables claves a lo largo de las doce semanas del proyecto.

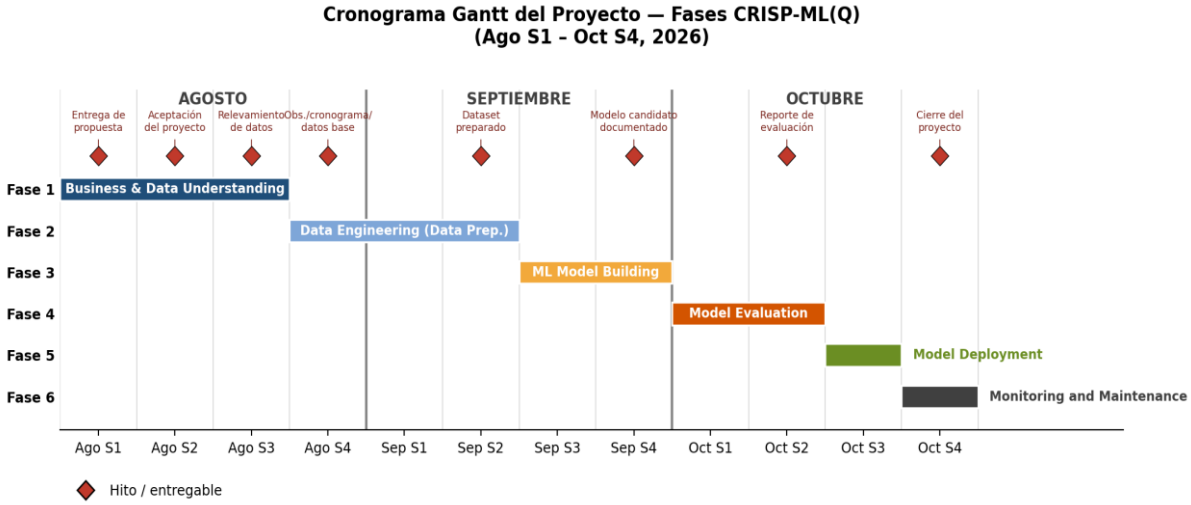


Ilustración 5 Diagrama de Gantt del cronograma propuesto

6 Costos del Proyecto

En relación con los costos estimados del proyecto, los mismo se cuantifican en base al número de horas hombre a invertir en el mismo por parte del equipo UDLA que presenta este trabajo, es decir 3 personas por un costo promedio base estimado para lograr cuantificar el esfuerzo de 20 dólares de los Estados Unidos de América por hora efectiva de trabajo de cada especialista. Este valor se ha obtenido luego un relevamiento de costos en el mercado local el mismo que se basa en entrevistas a empresas proveedoras de servicios de desarrollo de soluciones informáticas de software y gestión de datos.

La estimación de costos del proyecto se basa en un enfoque de costeo ascendente (bottom-up) por fase, alineado con las seis fases de la metodología CRISP-ML(Q) utilizada para estructurar el cronograma del proyecto (Studer et al., 2021), y siguiendo las recomendaciones metodológicas de estimación de costos de proyectos de inteligencia artificial que enfatizan un enfoque por fases con revisión de la intensidad de esfuerzo en cada una de ellas, dado el carácter iterativo y experimental de este tipo de desarrollos (Minkiewicz, 2025).

El valor de USD 20 por hora efectiva de trabajo se sustenta, además del relevamiento directo de mercado citado, en datos públicos de remuneración para perfiles de datos y aprendizaje automático (Data/BI/ML) en Ecuador, cuyo rango salarial mensual se ubica entre USD 1.800 y USD 4.000 según el nivel de especialización (Sueldo.ec, 2026), lo que equivale, considerando una jornada de 160 horas mensuales, a una tarifa de entre USD 11,25 y USD 25,00 por hora; el valor de USD 20 utilizado en esta estimación se ubica dentro de dicho rango, correspondiente a un perfil de especialización media.

La Tabla 5 desglosa la estimación de horas-persona y costo asociado por cada fase de la metodología CRISP-ML(Q), conforme al cronograma presentado en la sección 5.1.

Tabla 5 Estimación de costos por fase del proyecto (CRISP-ML(Q))

Fase CRISP-ML(Q)	Semanas	Horas-persona estimadas	Costo estimado (USD)
1. Business & Data Understanding	Ago S1–S3 (3)	54	$ 1.080,00
2. Data Engineering (Data Preparation)	Ago S4–Sep S2 (3)	90	$ 1.800,00
3. ML Model Building	Sep S3–S4 (2)	72	$ 1.440,00
4. Model Evaluation	Oct S1–S2 (2)	60	$ 1.200,00
5. Model Deployment	Oct S3 (1)	24	$ 480,00
6. Monitoring and Maintenance	Oct S4 (1)	18	$ 360,00
TOTAL	**12 semanas**	**318**	**$ 6.360,00**

El costo total estimado del proyecto asciende a USD 6.360,00, equivalente a 318 horas-persona distribuidas de forma no uniforme entre las seis fases, con mayor intensidad de esfuerzo en las fases de preparación de datos (Data Engineering) y construcción del modelo (ML Model Building), consistente con la literatura que señala que la preparación de datos puede representar una proporción sustancial del tiempo total de un proyecto de aprendizaje automático (Minkiewicz, 2025). Cabe señalar que esta estimación corresponde únicamente al esfuerzo del equipo de titulación (UDLA) y no incluye costos de infraestructura en la nube, licenciamiento de herramientas comerciales ni la dedicación del personal de la empresa involucrado en el relevamiento y la validación del proyecto.

7 Descripción de estudios realizados

Esta revisión de literatura evidencia tres grandes tendencias convergentes alrededor del problema abordado por este proyecto, centrado específicamente

en el pronóstico del volumen esperado de devolución. En primer lugar, existe un consenso creciente sobre la superioridad de los algoritmos de ensamblado basados en árboles —particularmente Random Forest y XGBoost, en su variante de regresión— frente a los métodos estadísticos clásicos (regresión lineal, ARIMA) para la predicción tanto de volúmenes de devolución como de demanda, especialmente cuando se dispone de múltiples variables explicativas y relaciones no lineales entre ellas. Karl (2024) documenta que, de 25 estudios revisados sobre pronóstico de devoluciones en e-commerce, la mayoría de los que emplean técnicas de aprendizaje automático reportan mejor desempeño que los modelos puramente estadísticos, incluso cuando las distribuciones de volumen de devolución son marcadamente sesgadas (muchos periodos con volúmenes bajos o nulos y pocos con volúmenes altos). Este hallazgo es confirmado por Mishra y Dutta (2024), quienes, trabajando con datos reales de la industria minorista, encontraron que Random Forest y los algoritmos de boosting superan consistentemente a los métodos de regresión clásicos en la estimación de variables relacionadas con las devoluciones, y por Nagadevi et al. (2025), quienes muestran una ventaja similar de XGBoost sobre SARIMA y árboles de decisión simples en el pronóstico del volumen de demanda en cadenas de suministro.

En segundo lugar, la literatura reciente enfatiza cada vez más la necesidad de explicabilidad (XAI) como condición para la adopción organizacional de estos modelos, más allá de su exactitud predictiva. Arboleda-Flórez y Castro-Zuluaga (2023) demuestran, en un caso de una empresa de venta directa, que incorporar SHAP dentro del proceso de pronóstico de demanda no solo mejora la comprensión de los resultados por parte de los equipos de negocio, sino que facilita la incorporación de conocimiento experto al pipeline de aprendizaje automático. En la misma línea, Kosasih et al. (2024) documentan, en su revisión de IA explicable en cadenas de suministro, múltiples aplicaciones de SHAP para interpretar modelos de árboles en tareas de gestión de inventario, incluyendo la predicción de quiebres de stock (backorders) y de riesgos de envío. Esta tendencia es directamente relevante para el proyecto, ya que respalda la inclusión de SHAP como mecanismo no solo de interpretación técnica del modelo, sino como insumo para un segundo paso —fuera del alcance actual— de identificación de causas raíz de devolución por distribuidor.

En tercer lugar, se observa una tendencia hacia la formalización metodológica del ciclo de vida completo de los proyectos de aprendizaje automático, más allá del entrenamiento del modelo. Studer et al. (2021), al proponer CRISP-ML(Q), documentan que la falta de un proceso estandarizado con puntos de control de calidad es una de las principales causas de fracaso de los proyectos de ML en producción, mientras que Kreuzberger et al. (2023) profundizan específicamente en las prácticas de MLOps (control de versiones de datos y modelos, monitoreo continuo, reentrenamiento automatizado) necesarias para sostener estos modelos una vez desplegados. Ambos marcos son la base metodológica adoptada explícitamente en este proyecto.

En cuanto a cómo ha sido abordado específicamente el problema de la predicción de devoluciones en investigaciones previas, la revisión muestra que

la mayoría de los estudios se concentran en el contexto de comercio electrónico business-to-consumer (B2C), es decir, devoluciones de clientes finales hacia un retailer en línea (Karl, 2024; Duong et al., 2022; Ambilkar et al., 2022). Este es precisamente el vacío que el presente proyecto busca cubrir: la aplicación de estas técnicas al contexto business-to-business (B2B) de una red de distribuidores mayoristas de telefonía celular, donde las devoluciones no provienen de consumidores individuales sino de distribuidores autorizados que gestionan inventario propio, un escenario más cercano al estudio de caso de Goulart et al. (2026) sobre un distribuidor de suministros de construcción, aunque este último se enfoca en pronóstico de demanda y no en devoluciones. Ningún estudio de los revisados aborda de forma específica la combinación de predicción de devoluciones con ajuste de demanda neta en el sector de telecomunicaciones, lo cual refuerza la pertinencia y originalidad del proyecto.

Finalmente, respecto a los vacíos identificados que se relacionan directamente con el problema organizacional del proyecto, destacan tres: (1) la escasa investigación sobre predicción del volumen de devoluciones en contextos de distribución mayorista o B2B, frente a la abundante literatura en B2C (Duong et al., 2022); (2) la limitada integración, en los estudios revisados, entre los modelos predictivos de volumen y los procesos de planificación de demanda ya existentes en las organizaciones, muchos de los cuales tratan el pronóstico como un ejercicio aislado y no como una capa incremental sobre procesos en producción (Fildes et al., 2022); y (3) la necesidad, señalada por Mehrabi et al. (2021), de auditar explícitamente los sesgos presentes en los datos históricos de devoluciones —por ejemplo, la sobre-representación de determinados distribuidores o zonas geográficas— antes de utilizarlos para entrenar modelos que orienten decisiones comerciales, un aspecto que ningún estudio de predicción de devoluciones revisado aborda de forma sistemática. Estos tres vacíos derivan directamente en las decisiones metodológicas adoptadas en la sección 5: adoptar un enfoque de regresión supervisada (Random Forest y XGBoost) centrado exclusivamente en la estimación del volumen esperado de devolución, que se integre como capa incremental al proceso de proyección de demanda vigente, incorporar SHAP para explicabilidad, y considerar explícitamente la representatividad de los datos de distribuidores durante la etapa de análisis exploratorio.

8 Desarrollo del proyecto

[Esta sección debe incluir de manera general una descripción del diseño y desarrollo de la solución máximo en un párrafo.]

8.1 Diseño de la solución

[Contenido:

- Enfoque metodológico aplicado.
- Fases del proyecto.

- Actividades realizadas.
- Herramientas utilizadas.
- Criterios de evaluación.

Ejemplo:

El proyecto se desarrolló en fases secuenciales desde el análisis del problema hasta el prototipo.]

8.2 Desarrollo de la solución

[Contenido:

- Descripción de los datos.
- Preprocesamiento resumido.
- Al menos dos alternativas técnicas.
- Justificación de la alternativa seleccionada.
- Uso de herramientas low-code/no-code.
- Arquitectura del prototipo.

Ejemplo:

Se compararon Random Forest y XGBoost, seleccionándose este último.]

8.3 Resultados y Discusión.

[Esta sección incluye los resultados que se espera al terminar el proyecto. Es importante usar indicadores y métricas relevantes. Se debe responder a las siguientes preguntas: ¿Qué se logró? (funcionalidades, tiempo de respuesta, eficiencia, usabilidad, etc.), ¿cuáles fueron los principales hallazgos? (Identificación de patrones o tendencias de los datos, etc.) y ¿qué significan los resultados? (Interpretación, comparativas, identificación de fortalezas y debilidades de la solución, etc.)]

8.4 Implicaciones éticas

[Esta sección incluye los temas éticos que se consideran en la solución y las implicaciones a las que se puede enfrentar el desarrollo y ejecución del proyecto.]

9 Conclusiones y Recomendaciones

[Esta sección incluye las conclusiones que se derivan de los objetivos planteados, además, las recomendaciones que se pueden desprender al final de la ejecución del proyecto.]

10 Trabajo futuro

[Esta sección incluye los posibles proyectos que se pueden generar a partir de los resultados de este.]

11 Referencias bibliográficas

Ambilkar, P., Dohale, V., Gunasekaran, A., & Bilolikar, V. (2022). Product returns management: A comprehensive review and future research agenda. International Journal of Production Research, 60(12), 3920–3944. https://doi.org/10.1080/00207543.2021.1933645

Angos Mediavilla, M., Dietrich, F., & Palm, D. (2022). Review and analysis of artificial intelligence methods for demand forecasting in supply chain management. Procedia CIRP, 107, 1126–1131. https://doi.org/10.1016/j.procir.2022.05.119

Arboleda-Flórez, M., & Castro-Zuluaga, C. (2023). Interpreting direct sales' demand forecasts using SHAP values. Production, 33, e20220035. https://doi.org/10.1590/0103-6513.20220035

Asamblea Nacional del Ecuador. (2021). Ley Orgánica de Protección de Datos Personales. Registro Oficial Suplemento No. 459, 26 de mayo de 2021.

Chaffey, D., Edmundson-Bird, D., & Hemphill, T. (2024). Digital business and e-commerce (8th ed.). Pearson.

Duong, Q. H., Zhou, L., Meng, M., van Nguyen, T., Ieromonachou, P., & Nguyen, D. T. (2022). Understanding product returns: A systematic literature review using machine learning and bibliometric analysis. International Journal of Production Economics, 243, 108340. https://doi.org/10.1016/j.ijpe.2021.108340

Fildes, R., Ma, S., & Kolassa, S. (2022). Forecasting in the age of AI: A review. International Journal of Forecasting, 38(1), 123–145. https://doi.org/10.1016/j.ijforecast.2021.09.001

Goulart, D. D., Baroni de Carvalho, R., Almeida Henriques, M., & Kawany Gonçalves Nunes Carvalho, B. (2026). Predictive models for inventory optimization: A machine learning application for demand forecasting at a construction supplies distributor. Future Business Journal, 12, Article 92. https://doi.org/10.1186/s43093-026-00807-8

GSMA Intelligence. (2024). The mobile economy Latin America 2024. GSMA.

Hyndman, R. J., & Athanasopoulos, G. (2021). Forecasting: Principles and practice (3rd ed.). OTexts.

International Organization for Standardization. (2023). ISO/IEC 25010:2023 – Systems and software engineering — Systems and software Quality Requirements and Evaluation (SQuaRE) — Product quality model.

Karl, D. (2024). Forecasting e-commerce consumer returns: A systematic literature review. Management Review Quarterly, 75(3), 1–56. https://doi.org/10.1007/s11301-024-00436-x

Kosasih, E. E., Papadakis, E., Baryannis, G., & Brintrup, A. (2024). A review of explainable artificial intelligence in supply chain management using neurosymbolic approaches. International Journal of Production Research, 62(4), 1510–1540. https://doi.org/10.1080/00207543.2023.2281663

Kreuzberger, D., Kühl, N., & Hirschl, S. (2023). Machine learning operations (MLOps): Overview, definition, and architecture. IEEE Access, 11, 31866–31879. https://doi.org/10.1109/ACCESS.2023.3262138

Laudon, K. C., & Laudon, J. P. (2022). Management information systems: Managing the digital firm (17th ed.). Pearson.

Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). A survey on bias and fairness in machine learning. ACM Computing Surveys, 54(6), 1–35. https://doi.org/10.1145/3457607

Minkiewicz, A. F. (2025). Cost estimation guidance for AI software development projects. Presentado en el ICEAA 2025 Professional Development & Training Workshop, Atlanta, GA. https://www.iceaaonline.com/wp-content/uploads/2025/06/MLN06-Minkiewicz-Guidance-for-AI-Software-Development-paper.pdf

Mishra, A., & Dutta, P. (2024). Return management in e-commerce firms: A machine learning approach to predict product returns and examine variables influencing returns. Journal of Cleaner Production, 477, 143802. https://doi.org/10.1016/j.jclepro.2024.143802

Nagadevi, S., Abirami, G., Vidhya, R., Selvakumar, S., & Vijayalakshmi, C. (2025). XGBoost-based demand forecasting in supply chain management using machine learning algorithm. International Journal of Interactive Mobile Technologies (iJIM), 19(18), 161–174.

Srivastav, A. L., Markandeya, Patel, N., Pandey, M., Pandey, A. K., Dubey, A. K., Kumar, A., Bhardwaj, A. K., & Chaudhary, V. K. (2023). Concepts of circular economy for sustainable management of electronic wastes: challenges and management options. Environmental Science and Pollution Research, 30(17), 48654–48675. https://doi.org/10.1007/s11356-023-26052-y

Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller, K.-R. (2021). Towards CRISP-ML(Q): A machine learning process model

with quality assurance methodology. Machine Learning and Knowledge Extraction, 3(2), 392–413. https://doi.org/10.3390/make3020020

Sueldo.ec. (2026). Cuánto gana un ingeniero de software en Ecuador 2026. https://www.sueldo.ec/blog/cuanto-gana-ingeniero-software-ecuador

12 Anexos

[En esta sección se incluye el detalle de lo que estime no indispensable para la comprensión del tema central, pero que lo complementa. También se debe incluir todos los documentos generados por la metodología usada en el desarrollo de la solución del problema. Ejemplos: Diagramas, Detalles de desarrollos de fórmulas, de experimentos realizados, tablas de estadísticas, gráficos, copia de documentos, leyes o reglamentos que no pueden ser parafraseados, etc. Los anexos se designarán en forma secuencial numérica (Anexo 1, Anexo 2, etc.).]